

# Gender-Aspekte der Data Science

## Sichtbarkeit von Forschenden auf Wikipedia im globalen Vergleich

Damian Rutz, Temirlan Anarkulov, Mary-Joyce Tonye Siade

2026-07-09

### Einleitung

Wikipedia gilt als eine der wichtigsten frei zugänglichen Wissensquellen weltweit und bestimmt teilweise, welche Forschenden öffentlich sichtbar sind. Wer einen Wikipedia-Artikel hat, in wie vielen Sprachen dieser Artikel existiert und wie ausführlich er ist, entscheidet mit darüber, wer als “bekannte Wissenschaftlerin” oder “bekannter Wissenschaftler” wahrgenommen wird. Diese Sichtbarkeit ist allerdings nicht zufällig verteilt. Frühere Studien zeigen immer wieder, dass Frauen in der Wissenschaft auf Wikipedia unterrepräsentiert sind, sowohl in absoluten Zahlen als auch in der Ausführlichkeit ihrer Artikel.

Dieses Projekt untersucht die Sichtbarkeit von Forschenden auf Wikipedia im Vergleich dreier Weltregionen, nämlich Afrika, Asien und der Westen (Deutschland, Frankreich, Italien, UK, USA). Grundlage sind Daten aus Wikidata, die über SPARQL-Abfragen gewonnen und anschließend mit der Wikipedia-REST-API ergänzt wurden. Im Zentrum stehen drei Fragen.

1. Wie stark unterscheidet sich die Wikipedia-Abdeckung von Forschenden zwischen den Regionen?
2. Gibt es einen Gender Gap in der Sichtbarkeit, gemessen an Sprachversionen und Abdeckung?
3. Wie strukturell ist dieser Gap, das heißt, zeigt er sich konsistent über Regionen und Teildatensätze hinweg?

Der folgende Code lädt, bereinigt und analysiert die Rohdaten schrittweise. Jeder Abschnitt kombiniert R-Code mit einer kurzen inhaltlichen Einordnung, damit der Analyseweg nachvollziehbar bleibt.

### Theoretischer Rahmen: Intersektionalität

Die vorliegende Analyse orientiert sich an der Intersektionalitätstheorie, wie sie maßgeblich von Kimberlé Crenshaw geprägt wurde. Der zentrale Gedanke dieses Ansatzes ist, dass sich

unterschiedliche Diskriminierungs- und Benachteiligungskategorien nicht einfach addieren, sondern sich gegenseitig durchdringen und in ihrer Wirkung verstärken können. Wer nur eine Kategorie isoliert betrachtet, etwa ausschließlich das Geschlecht oder ausschließlich die geografische beziehungsweise sprachliche Herkunft, läuft Gefahr, genau jene Gruppen aus dem Blick zu verlieren, für die sich mehrere Benachteiligungen überlagern.

Für dieses Projekt bedeutet das ganz konkret, dass die Fragestellung nicht lautet “Sind Frauen in der Wissenschaft auf Wikipedia unterrepräsentiert?” und auch nicht getrennt davon “Sind Forschende aus Afrika und Asien auf Wikipedia unterrepräsentiert?”. Stattdessen wird explizit danach gefragt, was passiert, wenn beide Kategorien gleichzeitig zutreffen. Eine Forscherin aus Nigeria oder Pakistan steht potenziell an der Schnittstelle zweier struktureller Benachteiligungen, der geografisch-medialen und der geschlechtsspezifischen. Ob sich diese beiden Achsen tatsächlich verstärken, neutralisieren oder in unerwarteter Weise gegenläufig wirken, lässt sich nur durch eine gemeinsame, regional wie geschlechtsspezifisch disaggregierte Betrachtung beantworten und nicht durch getrennte Analysen der beiden Dimensionen.

Diese theoretische Rahmung hat auch Konsequenzen für die Interpretation der Ergebnisse weiter unten in diesem Dokument. Wo sich beispielsweise zeigt, dass Frauen in einer Region zwar seltener überhaupt einen Wikipedia-Artikel besitzen, jene, die es “geschafft” haben, aber überdurchschnittlich viele Sprachversionen aufweisen, deutet das auf einen Selektionseffekt hin. Nur die sichtbarsten und bekanntesten Forscherinnen überschreiten offenbar die Schwelle zur Aufnahme in die Wikipedia, während für Männer diese Schwelle niedriger zu liegen scheint. Ein rein additives Diskriminierungsmodell würde diesen Effekt nicht abbilden können, da es Geschlecht und Region als unabhängige, sich nicht beeinflussende Faktoren behandeln würde.

Ein zweiter wichtiger Aspekt der Intersektionalitätsperspektive betrifft die Ebene, auf der Diskriminierung stattfindet. Es geht nicht um einzelne, isolierte Fälle von Unsichtbarkeit, sondern um strukturelle Bedingungen auf Infrastrukturebene. Wikipedia ist eine zentrale Quelle, aus der sich zahlreiche nachgelagerte Systeme speisen, etwa Google-Knowledge-Panels, akademische Suchwerkzeuge und die Trainingsdaten großer KI-Sprachmodelle. Wer auf Wikipedia unsichtbar bleibt, läuft Gefahr, auch aus diesen Folgeinfrastrukturen zu verschwinden.

## **Daten und Methodik**

Die Rohdaten liegen als länderspezifische CSV-Dateien vor, jeweils mit den Spalten `person`, `personLabel`, `country`, `countryLabel`, `genderLabel` und `wikipediaArticle`. Eine Person kann mehrfach vorkommen, nämlich einmal pro Sprachversion ihres Wikipedia-Artikels. Das ist methodisch wichtig, denn für Fragen wie “Wie viele Forschende gibt es pro Region?” muss dedupliziert werden, während für Fragen wie “Wie viele Sprachversionen hat eine Person im Schnitt?” genau diese Mehrfachzeilen gebraucht werden.

Die Länder werden zu drei Regionen zusammengefasst, Afrika (fünf ausgewählte Länder, siehe unten), Asien (China, Indien, Indonesien, Bangladesch, Pakistan) und Westen (Deutschland, Frankreich, Italien, UK, USA). Diese Einteilung ist eine bewusste Vereinfachung, um Aussagen

auf Regionsebene treffen zu können, ohne die statistische Aussagekraft einzelner Länder überzustrapazieren.

Insgesamt umfasst die Studie 15 Länder. Für Afrika wurden fünf bevölkerungsreiche Länder herangezogen, nämlich Nigeria, Äthiopien, Ägypten, Tansania und die Demokratische Republik Kongo. Diese Fünferauswahl wird bereits beim Einlesen der Rohdaten angewendet, sodass Afrika in der gesamten Analyse durchgängig auf diese fünf Länder beschränkt bleibt. Das stellt sicher, dass alle berichteten Kennzahlen für Afrika auf derselben, in sich konsistenten Datenbasis beruhen und direkt mit Asien und dem Westen vergleichbar sind. Für Asien wurden China, Indien, Indonesien, Bangladesch und Pakistan gewählt, für den Westen die USA, Deutschland, Frankreich, Italien und das Vereinigte Königreich.

Die Datenerhebung erfolgte über den öffentlichen SPARQL-Endpunkt von Wikidata, wobei gezielt nach Personen mit den Berufsbezeichnungen Wissenschaftler<sub>in</sub> (Q901) und Forscher<sub>in</sub> (Q1650915) gesucht wurde. Diese Eingrenzung schließt verwandte Kategorien wie Professor oder Akademiker aus. Das erzeugt einen gewissen Selektionsbias, sichert im Gegenzug aber die Vergleichbarkeit zwischen den Regionen, weil überall dieselbe Definition angewendet wird. Die Daten wurden im Juni 2026 erhoben.

```
library(tidyverse)
```

```
africa_5_countries <- c("Nigeria", "Ethiopia", "Egypt",  
                        "Tanzania", "Democratic Republic of the Congo")
```

```
africa <- read_csv("Afrika.csv") %>%  
  filter(countryLabel %in% africa_5_countries) %>%  
  mutate(region = "Africa")
```

```
asia <- bind_rows(  
  read_csv("China.csv"),  
  read_csv("Indien.csv"),  
  read_csv("Indonesien.csv"),  
  read_csv("Bangladesch.csv"),  
  read_csv("Pakistan.csv")  
) %>%  
  mutate(region = "Asia")
```

```
west <- bind_rows(  
  read_csv("Deutschland.csv"),  
  read_csv("Frankreich.csv"),  
  read_csv("Italien.csv"),  
  read_csv("UK.csv"),
```

```

  read_csv("USA.csv")
) %>%
  mutate(region = "West")

df_all <- bind_rows(africa, asia, west)
cat("Gesamtzahl Einträge (vor Deduplizierung):", nrow(df_all), "\n")

```

Gesamtzahl Einträge (vor Deduplizierung): 61803

## Deduplizierung

Da jede Zeile eigentlich eine Person-Artikel-Kombination ist, entstehen zwei unterschiedliche, aber gleichermaßen notwendige Datensätze. `df_clean` enthält genau eine Zeile pro Person und eignet sich für Zählungen wie “Wie viele Forschende gibt es?” oder “Wie ist die Geschlechterverteilung?”. `df_wiki` behält dagegen alle Person-Artikel-Kombinationen (nur für Personen mit mindestens einem Artikel) und ist die Grundlage für alles, was mit Sprachversionen zu tun hat.

```

df_wiki <- df_all %>%
  filter(!is.na(wikipediaArticle)) %>%
  distinct(person, wikipediaArticle, .keep_all = TRUE)

df_clean <- df_all %>%
  distinct(person, .keep_all = TRUE)

dupes <- nrow(df_all) - nrow(df_clean)
cat("Doppelte Einträge entfernt:", dupes, "\n")

```

Doppelte Einträge entfernt: 32090

```
cat("Eindeutige Forschende:", nrow(df_clean), "\n")
```

Eindeutige Forschende: 29713

Die Differenz zwischen `df_all` und `df_clean` entspricht damit nicht “Fehlern” im Datensatz, sondern schlicht der Anzahl zusätzlicher Sprachartikel pro Person. Das ist ein wichtiger Unterschied zu klassischer Duplikatsbereinigung, bei der doppelte Zeilen üblicherweise Datenfehler anzeigen.

## Forschende pro Region

Als erster Überblick zeigt sich, wie viele eindeutige Forschende pro Region in den Daten enthalten sind. Das ist zugleich die Grundgesamtheit für alle folgenden Prozentangaben.

```
df_clean %>%
  count(region, name = "n_researchers") %>%
  print()
```

```
# A tibble: 3 x 2
  region n_researchers
  <chr>      <int>
1 Africa      1325
2 Asia        5993
3 West       22395
```

## Wikipedia-Abdeckung pro Region

Die Abdeckung gibt an, wie viel Prozent der erfassten Forschenden überhaupt einen Wikipedia-Artikel besitzen. Unterschiede hier deuten auf strukturelle Sichtbarkeitsunterschiede zwischen den Regionen hin, etwa durch unterschiedliche Mediensysteme, Sprachräume oder die schiere Größe der jeweiligen Wikipedia-Communities.

```
wiki_coverage <- df_clean %>%
  group_by(region) %>%
  summarise(
    n_total = n(),
    n_with_wiki = sum(!is.na(wikipediaArticle)),
    n_without = sum(is.na(wikipediaArticle)),
    pct_with_wiki = round(n_with_wiki / n_total * 100, 1)
  ) %>%
  arrange(desc(pct_with_wiki))

print(wiki_coverage)
```

```
# A tibble: 3 x 5
  region n_total n_with_wiki n_without pct_with_wiki
  <chr>   <int>      <int>      <int>      <dbl>
1 West   22395        8341      14054        37.2
2 Asia   5993         1425       4568        23.8
3 Africa 1325          292       1033         22
```

Erwartungsgemäß dürfte der Westen hier tendenziell höhere Abdeckungsraten aufweisen, was weniger mit der wissenschaftlichen Relevanz der Forschenden zu tun hat als mit der Größe und Aktivität der jeweiligen Wikipedia-Editor:innen-Community.

## Geschlechterverteilung pro Region

Bevor der eigentliche Gender Gap in der Sichtbarkeit untersucht werden kann, muss zunächst die Ausgangsverteilung der Geschlechter in den Daten selbst betrachtet werden. Ist eine Region ohnehin schon stark männlich dominiert, muss das bei der Interpretation späterer Sichtbarkeitsunterschiede mitgedacht werden.

```
gender_dist <- df_clean %>%
  group_by(region, genderLabel) %>%
  summarise(n = n(), .groups = "drop") %>%
  group_by(region) %>%
  mutate(pct = round(n / sum(n) * 100, 1)) %>%
  arrange(region, desc(n))

print(gender_dist)
```

```
# A tibble: 19 x 4
# Groups:   region [3]
   region genderLabel      n  pct
   <chr>   <chr>      <int> <dbl>
1 Africa male          899  67.8
2 Africa female        392  29.6
3 Africa <NA>          33   2.5
4 Africa cisgender woman    1   0.1
5 Asia   male        2445  40.8
6 Asia   female      1821  30.4
7 Asia   <NA>       1724  28.8
8 Asia   trans woman     2    0
9 Asia   trans man       1    0
10 West  male       14950  66.8
11 West  female     6648  29.7
12 West  <NA>        741   3.3
13 West  trans woman    19   0.1
14 West  non-binary     17   0.1
15 West  undisclosed gender  9    0
16 West  trans man       6    0
17 West  genderqueer     3    0
```

```
18 West    cisgender man          1    0
19 West    genderfluid           1    0
```

```
check <- df_clean %>%
  count(region, name = "n_total_alle") %>%
  left_join(
    gender_dist %>% group_by(region) %>% summarise(n_total_summe = sum(n)),
    by = "region"
  )
print(check)
```

```
# A tibble: 3 x 3
  region n_total_alle n_total_summe
  <chr>      <int>         <int>
1 Africa      1325           1325
2 Asia        5993           5993
3 West       22395          22395
```

Anschließend wird die Wikipedia-Abdeckung getrennt nach Geschlecht innerhalb jeder Region betrachtet. Das ist der eigentliche Kern der Fragestellung, denn hier zeigt sich, ob Frauen in der Wissenschaft, unabhängig von ihrer ohnehin geringeren Zahl, zusätzlich noch seltener mit einem Wikipedia-Artikel bedacht werden als Männer.

```
gender_wiki <- df_clean %>%
  filter(genderLabel %in% c("male", "female")) %>%
  group_by(region, genderLabel) %>%
  summarise(
    n_total = n(),
    n_with_wiki = sum(!is.na(wikipediaArticle)),
    pct_wiki = round(n_with_wiki / n_total * 100, 1),
    .groups = "drop"
  ) %>%
  arrange(region, genderLabel)

print(gender_wiki)
```

```
# A tibble: 6 x 5
  region genderLabel n_total n_with_wiki pct_wiki
  <chr>   <chr>      <int>      <int>    <dbl>
1 Africa female      392         93    23.7
2 Africa male       899        199    22.1
```

|   |      |        |       |      |      |
|---|------|--------|-------|------|------|
| 3 | Asia | female | 1821  | 320  | 17.6 |
| 4 | Asia | male   | 2445  | 1027 | 42   |
| 5 | West | female | 6648  | 2483 | 37.3 |
| 6 | West | male   | 14950 | 5826 | 39   |

Die Tabelle zeigt noch einmal deutlich, was sich schon bei der Geschlechterverteilung angedeutet hat. Im Westen liegen Männer und Frauen bei der Wikipedia-Abdeckung fast gleichauf, in Asien ist der Abstand zugunsten der Männer dagegen viel größer. Dafür gibt es vor allem zwei Gründe. Erstens gibt es auf Wikipedia insgesamt weniger Biografien über Frauen, weil rund 90 Prozent der Autor:innen männlich sind und die Relevanzkriterien Themen bevorzugen, zu denen es bereits viel Medienberichterstattung gibt, ein Kriterium, das Frauen historisch seltener erfüllen. Zweitens kommen in Asien noch kulturelle Hürden dazu: traditionelle Rollenbilder, wirtschaftliche Ungleichheit und ein schlechterer Zugang zu digitaler Infrastruktur machen es Frauen dort schwerer, überhaupt sichtbar zu werden oder selbst als Wikipedia-Autorinnen aktiv zu werden. Zusammen erklärt das, warum der Unterschied zwischen den Geschlechtern in Asien so viel größer ist als im Westen.

In Afrika läuft es dagegen andersherum. Dort haben Frauen anteilig sogar etwas häufiger einen Wikipedia-Artikel als Männer. Ein Grund dafür sind gezielte Initiativen wie das Projekt [Wiki Loves Women](#), das genau deshalb gegründet wurde, weil afrikanische Frauen im Netz besonders unsichtbar waren. Es setzt gleich an zwei Lücken an, zu wenig Inhalte über Afrika allgemein und zu wenig Inhalte über Frauen im Besonderen. Das Projekt macht reale Vorbilder aus Politik, Wirtschaft und Wissenschaft sichtbar, wirkt den einseitigen Afrika-Bildern entgegen, die sich oft nur um Armut und Krisen drehen, und bringt Frauen bei, selbst Artikel zu schreiben. Diese gezielte Förderung dürfte mit ein Grund sein, warum sich das Geschlechterverhältnis bei der Artikelzahl in Afrika im Vergleich zu Asien umkehrt.

## Sprachabdeckung

Ein Wikipedia-Artikel allein sagt noch wenig über die tatsächliche Reichweite aus. Aussagekräftiger ist, in wie vielen Sprachversionen eine Person vertreten ist. Dazu wird zunächst der Sprachcode aus der URL des jeweiligen Artikels extrahiert.

```
langs <- df_wiki %>%
  mutate(lang = str_extract(wikipediaArticle, "(?<=https://)([a-z-]+)(?<=\\.wikipedia)")) %>%
  filter(!is.na(lang))

cat("Anzahl unterschiedlicher Sprachen pro Region:\n")
```

Anzahl unterschiedlicher Sprachen pro Region:



```
langs %>%
  group_by(region) %>%
  summarise(n_languages = n_distinct(lang)) %>%
  print()
```

```
# A tibble: 3 x 2
  region n_languages
  <chr>      <int>
1 Africa         78
2 Asia          126
3 West          281
```

Interessanter als die reine Anzahl verfügbarer Sprachen ist der Durchschnitt pro Person, also die Frage, wie viele Sprachversionen eine typische Forscherin oder ein typischer Forscher im Schnitt hat.

```
lang_per_person <- langs %>%
  group_by(region, person) %>%
  summarise(n_langs = n_distinct(lang), .groups = "drop")

lang_per_person %>%
  group_by(region) %>%
  summarise(
    mean_langs = round(mean(n_langs), 2),
    median_langs = median(n_langs),
    max_langs = max(n_langs)
  ) %>%
  arrange(desc(mean_langs)) %>%
  print()
```

```
# A tibble: 3 x 4
  region mean_langs median_langs max_langs
  <chr>      <dbl>         <dbl>    <int>
1 West      4.23           2      235
2 Africa    3.8            3       31
3 Asia      2.43           1       50
```

Ergänzend lohnt ein Blick auf die tatsächlich am häufigsten vorkommenden Sprachen pro Region, um die Ergebnisse besser einordnen zu können. So wird beispielsweise sichtbar, in welchem Ausmaß Englisch als “Standardsprache” wissenschaftlicher Sichtbarkeit fungiert.

```

langs %>%
  group_by(region, lang) %>%
  summarise(n_researchers = n_distinct(person), .groups = "drop") %>%
  group_by(region) %>%
  slice_max(n_researchers, n = 10) %>%
  print(n = Inf)

```

```

# A tibble: 30 x 3
# Groups:   region [3]
  region lang n_researchers
  <chr>  <chr>         <int>
1 Africa en           204
2 Africa ha           134
3 Africa ar           101
4 Africa ig            98
5 Africa sw            74
6 Africa arz           52
7 Africa fr            46
8 Africa yo            39
9 Africa ur            38
10 Africa es            25
11 Asia   en           746
12 Asia   zh           509
13 Asia   id           178
14 Asia   bn           169
15 Asia   ur           168
16 Asia   ta           134
17 Asia   te           133
18 Asia   pa            98
19 Asia   arz            84
20 Asia   hi            79
21 West   en          5962
22 West   de          2759
23 West   fr          2659
24 West   arz          1502
25 West   ar           1451
26 West   es           1123
27 West   ru           1021
28 West   pt            893
29 West   it            836
30 West   fa            688

```

## Geschlechterlücken pro Region

Nicht bei jeder Person ist in Wikidata ein Geschlecht hinterlegt. Fehlende Werte sind hier nicht zufällig, sondern können selbst ein Sichtbarkeitsindikator sein, denn wenn eine Person kaum Daten in Wikidata hat, fehlt oft auch das Geschlecht. Deshalb wird die Rate fehlender Geschlechtsangaben separat pro Region ausgewiesen.

```
df_clean %>%
  group_by(region) %>%
  summarise(
    n_total = n(),
    n_gender_missing = sum(is.na(genderLabel)),
    pct_missing = round(n_gender_missing / n_total * 100, 1)
  ) %>%
  arrange(desc(pct_missing)) %>%
  print()
```

```
# A tibble: 3 x 4
  region n_total n_gender_missing pct_missing
  <chr>   <int>         <int>         <dbl>
1 Asia     5993             1724         28.8
2 West    22395              741          3.3
3 Africa   1325              33           2.5
```

## Herausforderungen bei der Datenerhebung

Die Erhebung der Rohdaten war mit mehreren praktischen Schwierigkeiten verbunden, die an dieser Stelle dokumentiert werden, da sie für die Einordnung der Ergebnisse relevant sind. Erstens erwies sich der öffentliche SPARQL-Endpunkt von Wikidata als stark ausgelasteter Dienst, der wiederholt mit Timeouts und 502-Fehlern reagierte. Aus diesem Grund mussten die Abfragen länderspezifisch statt in einer einzigen globalen Abfrage ausgeführt werden. Für besonders datenreiche Länder wie das Vereinigte Königreich oder Deutschland waren zusätzlich LIMIT-Beschränkungen in den Abfragen notwendig, um überhaupt ein Ergebnis innerhalb des Zeitfensters des Endpunkts zu erhalten. Das bedeutet, dass für diese Länder nicht zwingend die vollständige in Wikidata erfasste Population an Forschenden vorliegt, sondern ein Ausschnitt davon.

Zweitens erwies sich die Deduplizierung der Daten als konzeptionell anspruchsvoller, als es zunächst scheinen mag. Da jede Person in den Rohdaten einmal pro Sprachversion ihres Wikipedia-Artikels erscheint, reicht eine einfache Duplikatsentfernung nicht aus. Stattdessen mussten zwei separate Datenstrukturen aufgebaut werden, `df_clean` für Personenzählungen

und `df_wiki` für die sprachbezogene Abdeckungsanalyse, je nachdem, welche Analyseeinheit für die jeweilige Fragestellung erforderlich ist.

Drittens war die Definition der Berufsbezeichnung selbst ein methodischer Kompromiss. Die Beschränkung auf die Wikidata-Kategorien Q901 und Q1650915 schließt, wie bereits erwähnt, verwandte Berufsgruppen aus. Diese Entscheidung sichert eine über alle 15 Länder hinweg vergleichbare Definition von “Forschenden”, auch wenn dadurch einzelne Personengruppen, etwa reine Hochschullehrende ohne diesen spezifischen Eintrag, aus der Analyse herausfallen.

Viertens fehlt in Asien bei 28,8 Prozent der erfassten Personen die Geschlechtsangabe in Wikidata, deutlich mehr als in den anderen Regionen. Diese Lücke wird nicht als Zufall behandelt, sondern als eigenständiger Befund, denn fehlende Geschlechtsangaben können selbst ein Symptom struktureller Datenlücken sein.

## Sprachabdeckung nach Geschlecht

Der eigentliche Kernvergleich der Analyse verbindet nun beide vorherigen Stränge, Sprachversionen und Geschlecht. Konkret wird geprüft, ob Forscherinnen im Schnitt weniger Sprachversionen ihres Artikels haben als Forscher, sowohl regional als auch global.

```
langs_gender <- df_wiki %>%
  mutate(lang = str_extract(wikipediaArticle, "(?<=https://)([a-z-]+)(?=\\.wikipedia)")) %>%
  filter(!is.na(lang)) %>%
  filter(genderLabel %in% c("male", "female"))

lang_per_person_gender <- langs_gender %>%
  group_by(region, person, genderLabel) %>%
  summarise(n_langs = n_distinct(lang), .groups = "drop")

lang_per_person_gender %>%
  group_by(region, genderLabel) %>%
  summarise(
    mean_langs = round(mean(n_langs), 2),
    median_langs = median(n_langs),
    n_researchers = n(),
    .groups = "drop"
  ) %>%
  arrange(region, genderLabel) %>%
  print()
```

```
# A tibble: 6 x 5
  region genderLabel mean_langs median_langs n_researchers
```

|   | <chr>  | <chr>  | <dbl> | <dbl> | <int> |
|---|--------|--------|-------|-------|-------|
| 1 | Africa | female | 5.41  | 4     | 93    |
| 2 | Africa | male   | 3.05  | 3     | 199   |
| 3 | Asia   | female | 3.57  | 2     | 320   |
| 4 | Asia   | male   | 2.18  | 1     | 1027  |
| 5 | West   | female | 3.41  | 2     | 2483  |
| 6 | West   | male   | 4.59  | 2     | 5826  |

Zusätzlich zur regionalen Betrachtung liefert die globale Aggregation über alle Regionen hinweg eine übergeordnete Kennzahl für den Gesamtvergleich zwischen den Geschlechtern.

```
cat("Global (alle Regionen zusammen):\n")
```

Global (alle Regionen zusammen):

```
lang_per_person_gender %>%
  group_by(genderLabel) %>%
  summarise(
    mean_langs = round(mean(n_langs), 2),
    median_langs = median(n_langs),
    n_researchers = n(),
    .groups = "drop"
  ) %>%
  print()
```

```
# A tibble: 2 x 4
  genderLabel mean_langs median_langs n_researchers
  <chr>         <dbl>         <dbl>         <int>
1 female         3.49             2         2896
2 male           4.19             2         7052
```

Ein durchgängig positiver Gap über alle Regionen hinweg würde darauf hindeuten, dass der Unterschied nicht auf einzelne kulturelle oder mediale Besonderheiten einer Region zurückzuführen ist, sondern ein strukturelles Muster darstellt.

## Diskussion und Fazit

Die Analyse zeigt ein mehrschichtiges Bild. Zunächst unterscheidet sich die reine Wikipedia-Abdeckung zwischen den Regionen deutlich. 37,2 Prozent der westlichen Forschenden verfügen über einen Wikipedia-Artikel, während dieser Anteil in Afrika und Asien mit 22 beziehungsweise

24 Prozent nahezu identisch und rund 15 Prozentpunkte niedriger ausfällt. Diese erste Sichtbarkeitslücke betrifft also weniger einen Unterschied zwischen Afrika und Asien als vielmehr einen klaren Abstand zwischen dem Westen und dem Rest der untersuchten Weltregionen.

Deutlich aufschlussreicher ist der zweite Schritt, der Vergleich der Wikipedia-Abdeckung zwischen Männern und Frauen innerhalb jeder Region. Hier zeigt sich ein überraschend uneinheitliches Bild. Im Westen herrscht nahezu Gleichheit, mit 39,0 Prozent abgedeckten Männern gegenüber 37,3 Prozent abgedeckten Frauen, ein Unterschied von lediglich 1,7 Prozent. In Asien ist der Unterschied dagegen deutlich größer, Männer sind dort 2,4-mal häufiger mit einem Wikipedia-Artikel vertreten als Frauen, 42 Prozent gegenüber lediglich 18 Prozent. In Afrika schließlich kehrt sich das Muster sogar leicht um, Frauen sind dort mit 24 Prozent geringfügig sichtbarer als Männer mit 22 Prozent. Diese Region-Geschlecht-Interaktion ist genau der intersektionale Befund, den die theoretische Rahmung dieser Studie erwarten ließ. Geschlecht wirkt eben nicht in allen Regionen gleich, sondern verstärkt oder überlagert die regionale Benachteiligung in unterschiedlicher Weise.

Ein dritter Baustein der Analyse betrifft die sprachliche Reichweite, gemessen an der Anzahl der Sprachversionen pro Person, allerdings nur unter den Forschenden, die überhaupt einen Wikipedia-Artikel besitzen. Im Mittel liegt der Westen hier mit 4,2 Sprachversionen vorn, gefolgt von Afrika mit 3,8 und Asien mit lediglich 2,3 Sprachversionen. Der Median zeichnet ein noch schärferes Bild. Die typische westliche Forscherin oder der typische westliche Forscher mit Artikel ist in zwei Sprachen vertreten, in Afrika sind es drei, in Asien hingegen nur eine einzige Sprache. Bemerkenswert ist dabei, dass Afrika hier vor Asien liegt, obwohl die absolute Zahl erfasster Forschender in Afrika mit 1.325 deutlich kleiner ist als in Asien mit 5.993. Sprachliche Reichweite und schiere Fallzahl korrelieren also nicht zwangsläufig.

Der vierte und für die Fragestellung dieser Studie wichtigste Befund verbindet Sprachreichweite und Geschlecht miteinander. Auch hier zeigt sich ein klar regionsabhängiges Muster. Im Westen sind Männer mit durchschnittlich 4,6 Sprachversionen leicht im Vorteil gegenüber Frauen mit 3,4 Sprachversionen, ein Unterschied von 1,18 Sprachversionen zugunsten der Männer, und damit die einzige der drei Regionen, in der Männer bei der Sprachreichweite vorne liegen. In Afrika und Asien kehrt sich dieses Verhältnis um, und zwar teils deutlich. In Afrika erreichen Frauen im Schnitt 5,4 Sprachversionen gegenüber 3,0 bei Männern, ein Unterschied von 2,36 Sprachversionen zugunsten der Frauen. In Asien liegen Frauen mit 3,6 Sprachversionen ebenfalls vor den Männern mit 2,2. Auf den ersten Blick liest sich das wie ein Vorteil für Forscherinnen in Afrika und Asien. Bei genauerer Betrachtung im Zusammenspiel mit dem ersten Befund, der geringeren Abdeckungsrate von Frauen in genau diesen beiden Regionen, ergibt sich jedoch ein anderes Bild. Es scheint, als würden es in Afrika und Asien nur die außergewöhnlich sichtbaren und bekannten Forscherinnen überhaupt bis auf Wikipedia schaffen, während für Männer die Aufnahmeschwelle niedriger liegt. Wer als Frau diese hohe Schwelle überwindet, wird im Anschluss überdurchschnittlich breit und mehrsprachig dokumentiert. Das ist kein Zeichen von Gleichstellung, sondern im Gegenteil ein Hinweis auf eine besonders selektive und damit verschärfte Hürde für die erste Sichtbarkeitsstufe.

Der Gender Gap bei der Wikipedia-Abdeckung in Asien, kombiniert mit dem gegenläufigen Muster bei der Sprachreichweite, spricht dafür, dass die geringere Sichtbarkeit von Forscherinnen kein regionaler Einzelfall ist, sondern ein strukturelles Muster in der Wissensproduktion von Wikipedia darstellt, das sich je nach Region auf unterschiedlichen Stufen zeigt. In Asien vor allem beim Zugang zu einem Artikel überhaupt, im Westen kaum messbar, in Afrika eher bei der Tiefe der sprachlichen Dokumentation.

Erwähnenswert ist dabei die Unterscheidung zwischen zwei Ebenen der Ungleichheit. Die erste Ebene betrifft die Repräsentation an sich, also wie viele Frauen überhaupt mit einem Artikel vertreten sind. Die zweite Ebene betrifft die Tiefe der Sichtbarkeit der Frauen, die es bereits geschafft haben. Der hier berechnete Sprachversionen-Gap adressiert genau diese zweite Ebene, wobei sich das Verhältnis in Afrika und Asien aus Selektionsgründen umkehrt.

Da Afrika in dieser Analyse durchgängig auf dieselben fünf Länder beschränkt ist, bereits ab dem Einlesen der Rohdaten, beruhen alle berichteten Kennzahlen für diese Region auf einer einheitlichen Datenbasis. Das erhöht die Aussagekraft der Vergleiche mit Asien und dem Westen, weil ausgeschlossen werden kann, dass unterschiedliche Befunde aus einer uneinheitlichen Definition von "Afrika" resultieren.

## **Warum diese Ergebnisse relevant sind**

Die Bedeutung dieser Befunde geht über eine einzelne Online-Enzyklopädie hinaus. Wikipedia-Artikel fließen inzwischen in eine Vielzahl nachgelagerter digitaler Systeme ein, etwa in die Trainingsdaten großer KI-Sprachmodelle, in die Knowledge Panels großer Suchmaschinen und in akademische Recherchewerkzeuge. Wer auf Wikipedia unsichtbar bleibt oder nur unzureichend in mehreren Sprachen abgedeckt ist, läuft daher Gefahr, auch aus diesen digitalen Folgeinfrastrukturen zunehmend zu verschwinden.

Entscheidend ist dabei die Ebene, auf der diese Untersuchung ansetzt, nämlich nicht einzelne fehlende Artikel, sondern die strukturellen Bedingungen, unter denen Wissen über bestimmte Personengruppen produziert, übersetzt und bewahrt wird. Ein Bias auf dieser Infrastrukturebene lässt sich nicht durch das Anlegen einzelner zusätzlicher Artikel korrigieren, sondern erfordert ein Verständnis der redaktionellen, sprachlichen und gesellschaftlichen Mechanismen dahinter.

## **Offene Fragen**

Die vorliegende Analyse beantwortet die eingangs gestellte Forschungsfrage nur in Teilen. Eine zentrale offene Frage betrifft den überraschenden Befund, dass Afrika bei der sprachlichen Reichweite vor Asien liegt, obwohl die absolute Zahl erfasster Forscher\*innen in Afrika deutlich kleiner ist. Es wäre lohnenswert zu untersuchen, ob dies an unterschiedlichen Sprachräumen, an der Aktivität bestimmter Wikipedia-Sprachversionen oder an Besonderheiten der jeweiligen Wissenschaftssysteme liegt.

Einschränkend gilt Folgendes. Die Daten stammen aus Wikidata und spiegeln damit vor allem, welche Forschenden dort überhaupt erfasst sind, was selbst schon eine Vorauswahl darstellt. Zudem bleiben fehlende Geschlechtsangaben eine Fehlerquelle, da unklar ist, ob sie zufällig verteilt sind oder selbst mit geringerer Sichtbarkeit korrelieren. Für weiterführende Arbeiten wäre es sinnvoll, zusätzlich die Artikellänge als Sichtbarkeitsmaß heranzuziehen sowie zeitliche Trends zu betrachten, um zu prüfen, ob sich der Gender Gap in jüngeren Kohorten von Forschenden verringert.